

Министерство науки и высшего образования РФ
Федеральное государственное автономное образовательное учреждение
высшего образования «Казанский (Приволжский) федеральный
университет»

ИНСТИТУТ ВЫЧИСЛИТЕЛЬНОЙ МАТЕМАТИКИ И
ИНФОРМАЦИОННЫХ ТЕХНОЛОГИЙ
КАФЕДРА ПРИКЛАДНОЙ МАТЕМАТИКИ И ИСКУССТВЕННОГО
ИНТЕЛЛЕКТА

Направление: 01.03.04 – Прикладная математика

Профиль: Прикладная математика

ОТЧЕТ ПО ПРОЕКТУ

«Многослойный персептрон»

По курсу «Анализ на Python»

Выполнил:

Студент группы 09-321

Суюндуков Г.Э.

Проверил:

Старший преподаватель

Гиниятова Д.Х.

Казань, 2026

Содержание

1	Введение	3
2	Разведочный анализ и предобработка данных	4
2.1	Разведочный анализ (EDA)	4
2.2	Стратифицированное разделение и устранение пропусков . .	4
2.3	Нормализация признаков	5
3	Архитектура нейронной сети и алгоритм обучения	6
3.1	Прямое распространение (Forward Pass)	6
3.2	Функция потерь и обратное распространение	6
3.3	Оптимизаторы: SGD и Adam	7
4	Оценка качества модели	8
4.1	Сравнение оптимизаторов	8
4.2	Анализ матрицы ошибок	8
5	Заключение	10

1 Введение

Целью данного проекта является реализация искусственной нейронной сети прямого распространения (многослойного персептрона) для решения задачи бинарной классификации. Все алгоритмы, включая прямое и обратное распространение ошибки, а также оптимизаторы SGD и Adam, реализованы исключительно с использованием библиотеки линейной алгебры NumPy. В качестве набора данных используется датасет Breast Cancer Wisconsin. Набор содержит 569 образцов и 30 числовых признаков, описывающих характеристики ядер клеток. Целевая переменная (диагноз) имеет два класса: **М** (злокачественная) и **В** (доброкачественная).

Архитектура проекта состоит из трех модулей:

1. `split.py` — разведочный анализ (EDA), предобработка и разделение данных;
2. `train.py` — реализация и обучение нейронной сети;
3. `predict.py` — прогнозирование на тестовой выборке и оценка качества модели.

2 Разведочный анализ и предобработка данных

2.1 Разведочный анализ (EDA)

Анализ распределения классов показал наличие дисбаланса (рис. 1): 357 образцов (62.7%) относятся к классу доброкачественных опухолей, и 212 образцов (37.3%) — к злокачественным.




Рис. 1: Распределение классов доброкачественных (В) и злокачественных (М) опухолей в датасете.

Для визуального анализа признаков были построены гистограммы и диаграммы размаха, позволившие выявить признаки, обладающие наибольшей разделяющей способностью (например, `concavity_mean`). Также была вычислена матрица корреляций Пирсона R :

$$R = \frac{\tilde{X}^T \tilde{X}}{n} \quad (1)$$

где $\tilde{X}$ — центрированная и нормированная матрица признаков.

2.2 Стратифицированное разделение и устранение пропусков

Данные были разделены на обучающую (80%) и валидационную (20%) выборки с сохранением пропорций классов (стратификацией). Для предотвращения *утечки данных* (*data leakage*) разделение производилось

до этапа нормализации и заполнения пропусков.

Заполнение возможных пропущенных значений осуществлялось не средним значением по всему датасету, а средним значением по соответствующему классу, вычисленным **только на обучающей выборке**. Это позволяет сохранить распределения признаков для каждого класса и не допустить смешивания характеристик доброкачественных и злокачественных клеток.

2.3 Нормализация признаков

Признаки имеют различные масштабы (например, `area_mean` достигает 2500, в то время как `smoothness_mean` находится в диапазоне 0.05-0.16). Для обеспечения стабильной и быстрой сходимости градиентного спуска применялась Z-score нормализация:

$$z = \frac{x - \mu}{\sigma} \quad (2)$$

Параметры μ и σ вычислялись строго по обучающей выборке и затем применялись к валидационной.

Целевая переменная была закодирована: $M \rightarrow 1$, $B \rightarrow 0$.

3 Архитектура нейронной сети и алгоритм обучения

3.1 Прямое распространение (Forward Pass)

Был реализован многослойный персептрон (MLP), принимающий на вход 30 признаков. Формула вычисления активаций l -го слоя:

$$Z^{[l]} = A^{[l-1]}W^{[l]} + b^{[l]}, \quad A^{[l]} = g(Z^{[l]}) \quad (3)$$

В качестве функции активации скрытых слоев используется сигмоида:

$$\sigma(z) = \frac{1}{1 + e^{-z}} \quad (4)$$

$$\sigma'(z) = \sigma(z)(1 - \sigma(z)) \quad (5)$$

На выходном слое (2 нейрона) применяется функция Softmax для получения вероятностного распределения по классам:

$$\text{softmax}(z_k) = \frac{e^{z_k - \max z}}{\sum_j e^{z_j - \max z}} \quad (6)$$

Вычитание максимума обеспечивает числовую стабильность вычислений.

Для инициализации весовых матриц использовался метод He Uniform:

$$W \sim U\left(-\sqrt{\frac{6}{n_{\text{in}}}}, \sqrt{\frac{6}{n_{\text{in}}}}\right) \quad (7)$$

3.2 Функция потерь и обратное распространение

В качестве функции потерь выбрана Categorical Cross-Entropy:

$$\mathcal{L} = -\frac{1}{m} \sum_{i=1}^m \sum_{k=0}^1 y_{ik} \log(\hat{p}_{ik}) \quad (8)$$

где y_{ik} — one-hot представление истинной метки класса, $\hat{p}_{ik}$ — предсказанная Softmax-вероятность.

Комбинация Softmax и Cross-Entropy дает численно стабильное выражение для градиента на последнем слое:

$$\delta^{[L]} = \frac{\partial \mathcal{L}}{\partial Z^{[L]}} = \hat{p} - y_{\text{one-hot}} \quad (9)$$

Градиенты для скрытых слоев вычисляются по правилу цепочки:

$$\delta^{[l-1]} = \left(\delta^{[l]} (W^{[l]})^T \right) \odot \sigma'(Z^{[l-1]}) \quad (10)$$

Градиенты весов и смещений:

$$\frac{\partial \mathcal{L}}{\partial W^{[l]}} = \frac{1}{m} (A^{[l-1]})^T \delta^{[l]} \quad (11)$$

$$\frac{\partial \mathcal{L}}{\partial b^{[l]}} = \frac{1}{m} \sum \delta^{[l]} \quad (12)$$

3.3 Оптимизаторы: SGD и Adam

Для обновления весов реализовано два алгоритма.

Мини-батч стохастический градиентный спуск (SGD):

$$W \leftarrow W - \eta \frac{\partial \mathcal{L}}{\partial W} \quad (13)$$

Adam (Adaptive Moment Estimation):

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t \quad (14)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2 \quad (15)$$

$$\hat{m}_t = \frac{m_t}{1 - \beta_1^t} \quad (16)$$

$$\hat{v}_t = \frac{v_t}{1 - \beta_2^t} \quad (17)$$

$$W \leftarrow W - \frac{\eta}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t \quad (18)$$

Алгоритм Adam адаптирует шаг обучения для каждого параметра, что значительно ускоряет сходимость.

4 Оценка качества модели

Обучение проводилось на архитектуре с двумя скрытыми слоями (64 и 32 нейрона) размером мини-батча 32. Основная используемая метрика для бинарной классификации — Binary Cross-Entropy (BCE). Для детального анализа использовались метрики Accuracy, Precision, Recall и F1-score.

4.1 Сравнение оптимизаторов

Сравнение эффективности оптимизаторов SGD ($\eta = 0.01$) и Adam ($\eta = 0.001$) показало превосходство адаптивного алгоритма:

Оптимизатор	Эпохи	Accuracy (Val)	BCE Loss (Val)
SGD	50	93.81%	0.264
Adam	100	98.23%	0.114

Таблица 1: Сравнение оптимизаторов на валидационной выборке

4.2 Анализ матрицы ошибок

Для лучшей модели (Adam) была построена матрица ошибок (Confusion Matrix) на валидационной выборке ($N = 113$), представленная в таблице 2 и на рисунке 2.

	Предсказан В	Предсказан М
Истинный В	71 (TN)	0 (FP)
Истинный М	2 (FN)	40 (TP)

Таблица 2: Матрица ошибок

Результаты показывают отсутствие ложных срабатываний (Precision для класса М равен 1.0). Из 42 злокачественных опухолей модель успешно выявила 40 (Recall = 0.952), F1-мера для целевого класса составила 0.975. Отсутствие переобучения подтверждается тем, что кривые обучения (Loss и Accuracy) для обучающей и валидационной выборок сходятся на графиках синхронно (рис. 3).




Рис. 2: Визуализация матрицы ошибок для модели, обученной оптимизатором Adam.




Рис. 3: Кривые обучения функции потерь (слева) и точности (справа) для оптимизатора Adam. Сходимость тренировочных и валидационных кривых указывает на отсутствие переобучения.

5 Заключение

В ходе выполнения проекта была с нуля разработана полностью функциональная библиотека для создания нейронных сетей, поддерживающая абстракции слоев, функций активации и оптимизаторов. Модель многослойного персептрона успешно решила задачу классификации клеток молочной железы, достигнув точности в 98.23% на отложенной выборке. Использование современных подходов (He Uniform, Softmax+Cross-Entropy, нормализация без утечки данных, Adam) доказало свою эффективность.